

機器學習期末報告

Airbnb New User Bookings https://www.kaggle.com/c/airbnb-recruiting-new-user-bookings



巨資四 B 英文四 B 05170282 05121232 陳盈君 羅苡禎

目錄

一、 比賽說明

二、 過程說明

三、 整體分析及檢討

四、 Kaggle 分數

五、 心得

六、 參考資料

一、比賽說明

Airbnb旅行者沒有醒來就忽略了"請勿打擾"的標誌,而是發現自己在異想天開的樹屋中與鳥類一同起床,在船屋甲板上喝咖啡,或與房東共享區域早餐。Airbnb的新用戶可以預訂在190多個國家/地區的34,000多個城市中居住的地方。通過準確預測新用戶將在哪裡預訂他們的第一次旅行體驗,Airbnb可以與社區共享更多個性化的內容,減少首次預訂的平均時間,並更好地預測需求。

二、過程說明

將呈現兩個檔案的執行流程

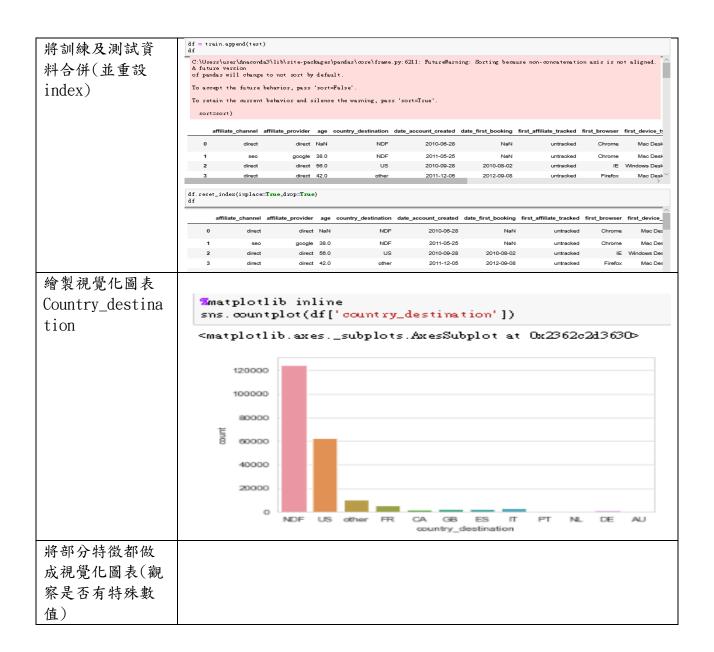
兩個檔案的原因:第一個檔案基本上是按照老師課堂所教的方法再加上網路的 資料參考而完成的,有可能因為資料清整的不夠乾淨或是最後索取的變數不夠 精確,所以分數不高;基於已經修改多次程式碼,於是又製作一份新的檔案。 不過第二份程式碼參考較多網路來源(原創部分較少),因此我們決定將兩份檔 案都放上來比較,最後也會附註參考資料來源。

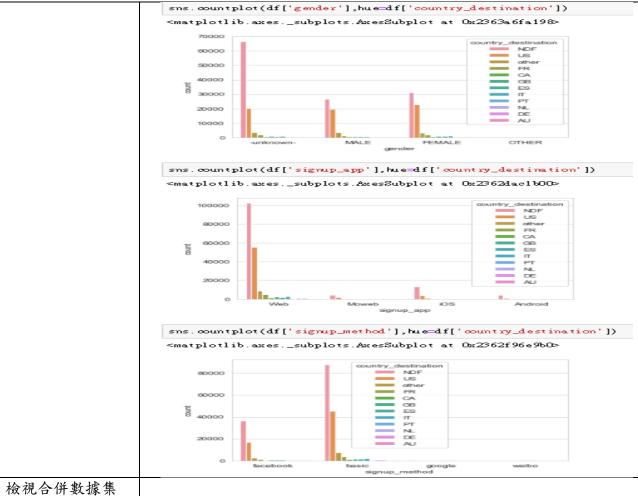
■ 大綱:

讀取檔案-理解檔案內容(如:缺失值、資料型態等)-繪製視覺化圖表(幫助自己更好的理解數據分布狀況以及了解某些特殊狀況)-資料清整(將離群值或是缺失值做刪除或填補的動作)-選擇要放入模型的變數(這步非常重要,是否所選的每個變數與最終結果是有正向關聯)-模型篩選(選擇適合的模型以便有更精確的預測)-檔案儲存-上傳Kaggle-事後檢討、分析-心得(反思)

■ 自行製作程式:

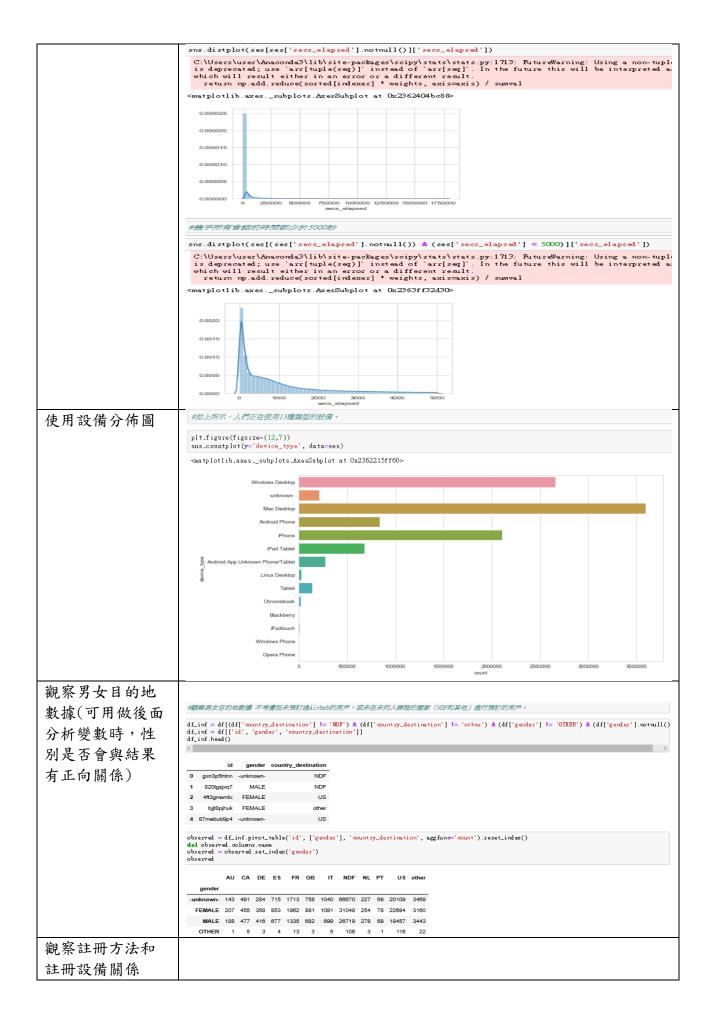
```
### from sklearn import preprocessing import pandas as pd import mandas as pd import matplotlib.pyplot as plt import matplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotlib.pyplotl
```





檢視合併數據集 某些變數-觀察用戶註冊時 間到訂房的時間 差(可看出有少數 離群值)

針對年齡這項變 數做初步檢視(觀 df.age.describe() 察是否有離群值 158681.000000 count 47. 145310 142. 629468 1.000000 28.000000 42.000000 42.000000 2014.000000 mean std 或是不合理的數 min 25% 50% 75% 值) 進行年齡數據初 max 2014.000000 Name: age, dtype: float64 步調整(將不合理 df[df.age>1000]['age'].describe() 828.000000 2007.117150 22.219408 1920.000000 2014.000000 2014.000000 2014.000000 的值替换掉) count mean std min 25% 50% max 2014.000000 Name: age, dtype: float64 df[df.age< 18].age.describe() count 188.000000
mean 12.718085
std 5.764569
min 1.000000
25% 5.000000
55% 16.000000
75% 17.000000
max 17.000000
Name: age, dtype: float64 ##16歲其實還算合理,5歲不太合理,我們可以將16歲當作一個filter(關值)把數字濾掉。 #1歲有可能會是以公司名義創辦的帳號,有的公司會以創立年份當作歲數(但依舊屬於繼群值可清除) 年龄數據分佈圖(plt. figure(figsize = (12, 6))
sns.distplot(df.age.dropma(), rug = True)
sns.despine() 可看出普遍用戶 年龄落點位置) C:\Users\user\Anaconda3\lib\site-packages\scipy\stats\stats.py:1713: FutureWarning: Using a non-tuple is deprecated; use `arr[tuple(seq)]' instead of `arr[seq]'. In the future this will be interpreted as which will result either in an error or a different result.
return np.add.reduce(sorted[indexer] * weights, axis=axis) / sumval 0.05 0.04 ##觀察年齡分佈 #發現25-40歲左右是主要答群 Sessions資料讀 取後,取變數停 留時間做視覺化 圖表(了解用戶普 遍停留時長)



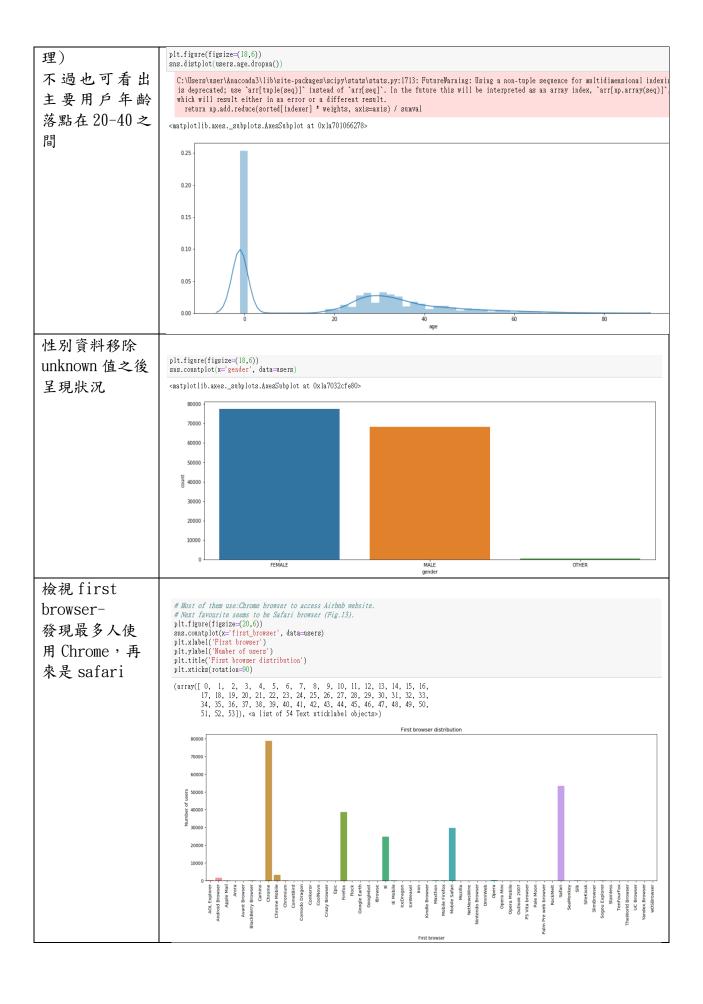
#註冊方法和註冊設備之間的關係。 #大多數用戶連通標準的基本方法或通過Facebook進行註冊。 #多數使用桌面瀏覽器,移動瀏覽器或移動應用程序登錄。 #記憶的類型(移動或計算機)是否會影響Airbub的註冊方法 #忽略Google註冊方法,因為實例較少。 #我們將iOS,Moweb和Android視為移動設備類型。 $\begin{array}{l} df_signup = df[(df['signup_method'] != 'google')][['id', 'signup_method', 'signup_app']] \\ df_signup['device'] = df_signup['signup_app'].apply(lambda x: 'Computer' if x = 'Web' else 'Mobile') \\ df_signup.head() \\ \end{array}$ id signup_method signup_app device 0 gxn3p5htnn facebook Web Computer 1 820tgsjxq7 facebook Web Computer Web Computer 4ft3gnwmtx bjjt8pjhuk Web Computer 4 87mebub9p4 basic Web Computer df_sigrup['sigrup_method'].value_counts() basic 198222 facebook 74864 weibo 23
Name: signup_method, dtype: int64 df_sigmup['device'].value_counts() Computer Mobile 219917 53192 Name: device, dtype: int64 觀查各國人口統 #將各個國家的年齡和性別統計數據可視化。 plt.figure(figsize=(20,8))
sns.barplot(x='age_bucket', y='population_in_thousands', hue='gender', data=age_gen, oi=None) 計(了解最大群體 <matplotlib.axes._subplots.AxesSubplot at 0x2361f7d3278> 的歲數) gender male famale #觀察結果 #該統計數據中所代表的國家主要是人口老齡化。最大的詳麗是50-54歲的人群。。 #檢製每個國家的人口圖。 透過視覺化圖表sns.set_style('whitegrid') 得知美國是用戶 plt.figure(figsize=(10,7)) pop_stats = age_gen.groupby('country_destination')['population_in_thousands'].sum()
sns.barplot(x=pop_stats.index, y=pop_stats) 最爱前往的國家 <matplotlib.axes._subplots.AxesSubplot at 0x236619add68> 250000 200000 150000 100000

```
模型變數篩選並
進行資料類別型
態轉換

df['agnup_method'] = df['gender'].astype('category').cat.codes df['algnup_method'] = df['affiliate_provider'].astype('category').cat.codes df['affiliate_provider'] = df['affiliate_provider'].astype('category').cat.codes df['affiliate_provider'] = df['defiliate_provider'].astype('category').cat.codes df['affiliate_provider'] = df['defiliate_provider'].astype('category').cat.codes df['affiliate_provider'] = df['defiliate_provider'].astype('category').cat.codes df['defiliate_provider'].astype('defiliate_provider'].astype('defiliate_provider').astype('defiliate_provider').astype('defiliate_provider').astype('defiliat
```

■ 網路參考程式:

```
檔案讀取
                     # Load the data into DataFrames
                     from sklearn import preprocessing
                     import pandas as pd
                     import numpy as np
                     import matplotlib.pyplot as plt
                     import seaborn as sns
                     import matplotlib as mpl
                     import seaborn.apionly as sns
                     train_users = pd.read_csv("C:/Users/user/Desktop/train_users_2.csv")
                    test_users = pd.read_csv("C:/Users/user/Desktop/test_users.csv")
age_gender = pd.read_csv("C:/Users/user/Desktop/age_gender_bkts.csv")
                    sessions=pd.read_csv("C:/Users/user/Desktop/sessions.csv")
                    countries=pd.read_csv("C:/Users/user/Desktop/countries.csv")
將訓練和測試
                    users = pd.concat((train_users, test_users), axis=0, ignore_index=True)
資料做合併
將類別資料做
處理
                    categorical_features = [
                        'affiliate_channel',
'affiliate_provider'
                        'country_destination'
                        'first_affiliate_tracked',
                        'first_browser',
                        'first_device_type',
                         gender'.
                        'language'
                         signup_app'
                        'signup_method'
                    for categorical feature in categorical features:
                        users[categorical_feature] = users[categorical_feature].astype('category')
字串轉換成時
                     users['date_account_created'] = pd.to_datetime(users['date_account_created'])
                     users['date_first_booking'] = pd.to_datetime(users['date_first_booking'])
間格式
                    users['date_first_active'] = pd.to_datetime(users['timestamp_first_active'], format='%Y%m%d%H%M%S')
將年齡資料做
                    users.loc[users.age > 85, 'age'] = np.nan
                    users.loc[users.age < 18, 'age'] = np.nan
處理-再以視覺
                    users['age'].fillna(-1,inplace=True)
化圖表呈現
                    bins = [-1, 0, 4, 9, 14, 19, 24, 29, 34,39,44,49,54,59,64,69,74,79,84,89]
可看出部分數
                    users['age_group'] = np.digitize(users['age'], bins, right=True)
值集中在零歲
(基本來看不合
```



```
檢視 sessions
                     display(sessions.isnull().sum())
資料(檢查空
                                                                     34496
                          user_id
                                                                     79626
                          action
值)
                                                                 1126204
                          action_type
                          action_detail
                                                                 1126204
                          device_type
                          secs_elapsed
dtype: int64
                                                                   136031
檢視使用設備
                    #the most popular device to access Airbnb seems to be Mac Desktop plt.figure(figsize=(18,6)) sns.countplot(x='device_type', data=sessions) plt.xlabel('Device_type') plt.ylabel('Number of sessions') plt.tile('Device_type distribution') plt.xticks(rotation=90)
的情况-最多人
使用的是 mac
desktop
                    (array([ 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13]), <a list of 14 Text xticklabel objects>)
                                                         Device type distribution
檢視有修正過
                     countries.info()
部分數據的
countries 資料
                        <class 'pandas.core.frame.DataFrame'>
                        RangeIndex: 10 entries, 0 to 9
                        Data columns (total 7 columns):
                        country_destination
                                                                     10 non-null object
                        lat_destination
                                                                     10 non-null float64
                        lng_destination
                                                                     10 non-null float64
10 non-null float64
                        distance_km
                        destination_km2
                                                                     10 non-null float64
                        destination_language
                                                                     10 non-null object
                        language_levenshtein_distance
                                                                     10 non-null float64
                        dtypes: float64(5), object(2) memory usage: 640.0+ bytes
Sessions-
                    sessions.rename(columns = {'user_id': 'id'}, inplace=True)
做 rename 的步
驟
```

```
針對-
                           from sklearn import preprocessing
                           # Create a minimum and maximum processor object
每種動作類型
                           min_max_scaler = preprocessing.MinMaxScaler()
的計數、
                           action_count = sessions.groupby(['id'])['action'].nunique()
每個動作經過
                           \#action\_count = pd.DataFrame(min\_max\_scaler.fit\_transform(action\_count.fillna(0)), columns = action\_count.columns)
的時間總和、
                           action_type_count = sessions.groupby(['id', 'action_type'])['secs_elapsed'].agg(len).unstack()
                           action_type_count.columns = action_type_count.columns.map(lambda x: str(x) + '_count')
每種操作類型
                           \#action\_type\_count = pd.DataFrame(min\_max\_scaler.fit\_transform(action\_type\_count.fillna(0)), columns = action\_type\_count.columns)
                           action_type_sum = sessions.groupby(['id', 'action_type'])['secs_elapsed'].agg(sum)
經過的時間與
用戶經過的總
                           {\tt action\_type\_pcts} = {\tt action\_type\_sum.groupby(level=0).apply(lambda~x:}
                                                                100 * x / float(x.sum())).unstack()
時間的關係..
                           action_type_pcts.columns = action_type_pcts.columns.map(lambda x: str(x) + '_pct')
                           action_type_sum = action_type_sum.unstack()
等數據。
                           action\_type\_sum.columns = action\_type\_sum.columns.map(lambda \ x: \ str(x) + '\_sum')
將所有數據與
                           action_detail_count = sessions.groupby(['id'])['action_detail'].nunique()
用戶數據合併
                           #action_detail_count = pd.DataFrame(min_max_scaler.fit_transform(action_detail_count.fillna(0)),columns=action_detail_count.columns)
                           device_type_sum = sessions.groupby(['id'])['device_type'].nunique()
                           #device_type_sum = pd.DataFrame(min_max_scaler.fit_transform(device_type_sum.fillna(0)),columns=device_type_sum.columns)
                           sessions_data = pd.concat([action_count, action_type_count, action_type_sum,action_type_pcts,action_detail_count, device_type_sum],axis=1)
                           action count = None
                           action_type_count = None
                           action_detail_count = None
                           device_type_sum = None
                           #users = users.join(sessions data, on='id')
                              users= users.reset_index().join(sessions_data, on='id')
Encode
                           from sklearn.preprocessing import LabelEncoder
categorical
                           categorical features = [
features-
                              'gender', 'signup_method', 'signup_flow', 'language',
對分類特徵進
                              'affiliate channel', 'age group', weekday account created', month account created', weekday first active', month first active', hour first a
行編碼:編碼為
                              signup_app','affiliate_provider', 'first_affiliate_tracked','first_device_type', 'first_browser''
數值
使用: one hot
                           users_sc = users.copy(deep=True)
encoding
                           encode = LabelEncoder()
                           for j in categorical features:
                              users sc[j] = encode.fit transform(users[j].astype('str'))
                           colx = users_sc.columns.tolist()
Feature
                           rm_list = ['id','country_destination']
for x in rm_list:
Selection-
                                  colx.remove(x)
從用戶和
                           X = users_sc[~(users_sc['country_destination'].isnull())][colx]
sessions提取
                           X.fillna(0,inplace=True)
                           from sklearn.feature_selection import VarianceThreshold
了54個功能
                           sel = VarianceThreshold(threshold=(0.8))
因此,執行特
                           sel.fit_transform(X)
                           idxs = sel.get_support(indices=True)
徵選擇,減少
                           colo = [X.columns.tolist()[i] for i in idxs]
數量
                           print ('\n'.join(colo))
                           for y in rm_list:
消除了具有低
                                 colo.append(y)
閾值的變量,
並產生最終列
```

```
affiliate_channel
                     affiliate_provider
first_affiliate_tracked
                     first_browser
                     first_device_type
                     gender
                     language
                     signup_flow
                     age_group
                     weekday_account_created
                     month_account_created
                     weekday_first_active
month_first_active
                     month_first_book
                     hour_first_active
                     time_lag_create
time_lag_active
                     action
                     -unknown- count
                     click_count
                     data_count
                     message_post_count
submit_count
                     view_count
                     -unknown-_sum
booking_request_sum
                     booking_response_sum
                     click_sum
                     data sum
                     message_post_sum
                     partner_callback_sum
                     submit sum
                     view_sum
                      -unknown-_pct
                     booking_request_pct
                     click_pct
                     message_post_pct
                    categorical_features_1 = [val for val in categorical_features if val in colo]
                    users_encode = pd.get_dummies(users[colo], columns=categorical_features_1)
Countries and
                   from time import time
                    from math import sqrt
Age Bkdts
                    import logging
dataset-
                    import os
部分有價值的
                   import sys
                    import csv
信息(但目前可
                    import datetime
使用部分不多)
                   total = {}
                   started = {}
                   model_perf={}
                   def start(key):
                        started[key]=time()
                   def stop(key):
                        stop=time()
                        start=started.pop(key,None)
                        if start:
                             if key in total:
                                 total[key].append(stop-float(start))
                                  total[key]=[stop-float(start)]
                        else:
                             logging.error("stopping non started timer: %s"%key)
```

```
from sklearn.model_selection import train_test_split
切割訓練、測
                         users.set_index('id',inplace=True)
試數據集
                         users.drop([col for col in users.columns if 'pct_booking_request' in col],axis=1,inplace=True)
users.drop([col for col in users.columns if 'booking_request_count' in col],axis=1,inplace=True)
其中,
                         colx = users.columns.tolist()
                         #colx_1 = users_data_1.columns.tolist()
time_lag_crea
                         rm_list = ['country_destination','month_first_book', 'time_lag_create','time_lag_active']
                         for x in rm_list:
tive
                            colx.remove(x)
                         X_1 = users[(users['country_destination'].isnull())][colx]
和
                         X_1.fillna(0,inplace=True)
                         X = users[~(users['country_destination'].isnull())][colx]
#X_1 = users_data_1[~(users_data_1['country_destination'].isnull())][colx_1]
Y = users[~(users['country_destination'].isnull())]['country_destination']
time lag acti
ve 通過方差閾
                               users_data_1[~(users_data_1['country_destination'].isnul1())]['country_destination']
                         X.fillna(0,inplace=True)
值方法以及我
                         #X_1.fillna(0,inplace=True)
                         #X_res,Y_res = ada.fit_sample(X, Y)
們構建的決策
                         X_train, X_test, Y_train, Y_test = train_test_split(X, Y, test_size=0.2, random_state=42,stratify=Y)
                         #X_train_1, X_test_1, Y_train_1, Y_test_1 = train_test_split(X_1, Y_1, test_size=0.2, random_state=42,stratify=Y)
樹和隨機森林
模型都被標為
關鍵特徵。
但因為目前模
型較不需要,
因此排除了這
兩項變數
                         from sklearn.tree import DecisionTreeClassifier
模型使用隨機
                         dt = DecisionTreeClassifier()
森林
                         dt.fit(X_train, Y_train)
                         DecisionTreeClassifier(class_weight=None, criterion='gini', max_depth=None,
                                         max_features=None, max_leaf_nodes=None,
                                         min_impurity_decrease=0.0, min_impurity_split=None,
                                         min_samples_leaf=1, min_samples_split=2,
                                         min_weight_fraction_leaf=0.0, presort=False, random_state=None,
                                         splitter='best')
最後結果預測
                        y_pred_prob_1=dt.predict_proba(X_1)
                         id_test = X_1.reset_index()['id']
及存成檔案-便
                         ids = [] #list of ids
cts = [] #list of countries
可上傳 kaggle
                         for i in range(len(id_test)):
                              idx = id_test[i]
                              ids += [idx] * 5
                              arr = [dt.classes_.tolist()[k] for k in np.argsort(y_pred_prob_1[i])[::-1]]
                             cts += arr[:5]
                         #Generate submission
                         sub = pd.DataFrame(np.column_stack((ids, cts)), columns=['id', 'country'])
                         sub.to_csv('sub_dt.csv',index=False)
```

三、整體分析及檢討

主要針對自行製作程式方面(網路參考程式的過程都在第二點有介紹): 整體而言,最一開始的數據讀取到做基本視覺化圖表,不管是何種寫法呈現出的結果都是大同小異的。但開始進行細項變數清整後就有落差了。 讀取資料時:

- · 發現date_first_booking的缺失值很多,而且在測試集中的數據為零,這時便可判斷最終執行時不會採用這項變數。
- · 進行年齡讀取時發現有部分極端值(例如:超過100歲或是只有1歲),某些 層面來說是有人故意填寫非真實數值的。這點我曾在實習時遇過,事後發

現會有以公司名義註冊的帳號,所以年齡便是公司成立年數;但這並非個人名義,所以此種數值依舊需要清整(以平均值替代或是刪除)

· 有一點關於設備的特殊發現是多數有訂房的用戶都是使用蘋果相關的產品 (舉凡:手機、平板、電腦),而且美國是最熱門的地點;因此,我們天馬 行空的發想,是否普遍用戶都對美國有憧憬(也對他們產品特別偏愛)

最後選取變數要進行模型測試時,我們自行製作的程式選擇了較多認為有相關的變數實測,至於模型的選擇,我們發現決策樹所測出的分數都較好,不管是自行製作還是網路參考的都是。而網路參考的程式也使用蠻多變數,但都有進行更進階的清整,所以最終結果較我們製作的好。而根據我們爬文所了解關於使用模型的資訊是,普遍的人推薦xgboost或是做久了自然能了解何種模型會有較佳的結果,但這次我們都是使用決策樹。

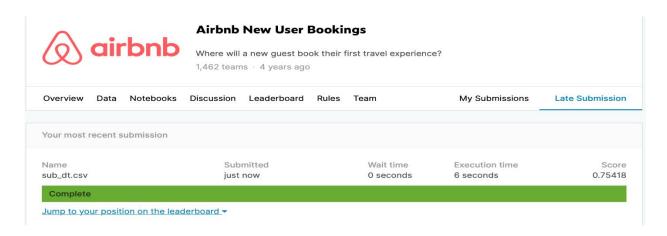
- 關於自行製作程式的反思:我們認為在進行數據清整時應該更仔細(可能要再把數據分得更細),以及再更準確的判斷何種變數是真正和結果有正相關的。
- 關於網路參考程式的反思:見識到許多較複雜的寫法,花了不少時間才能釐清他們如此使用的原因;儘管無法很好地應用到自行製作的程式,但至少知道如何將優點彙整起來且稍微精簡,做出一個較好的模型。

四、Kaggle 分數

自行製作程式分數:

您最近的提交				
名稱 Submit.csv	已提交 2分鐘前	等待時間 0 秒	執行時間處理時間 O 秒	得分了 0.57708
完成				
跳至排行榜上的位置▼				

網路參考程式分數:



五、心得

■ 羅苡禎:

這次的期末報告,確實不好寫。自己要做出像樣的資料清整、分類回歸,對我來說很不容易。所以,一邊參考老師的上課講義,一邊參考網路上高手們的程式碼。一邊做一邊學,也學到很多資料分析的邏輯和好方法,收穫不少。 學習理論需要真正的應用和實踐,才是一件有意義的事情。做這次的期末報告,像幫自己做了個總複習。身為外系的我程式碼非常待加強。幸好在同組夥伴的幫助下,雖然費了很大的心力,作業最終完成了。

■ 陳盈君:

這次的期末報告對我來說是困難的,雖然平時上課有跟上老師的進度、回家作業也有確實完成,但要完全寫出一個原創的程式碼還是有難度的。但在寫的過程中一邊寫一邊思考、了解哪部分的程式碼出了問題應如何修正及整體分析文件的邏輯,這都是期末報告能學到的。雖然自己寫出的程式碼分數有點悽慘,必須參考網路上的資料才能完成報告,但能順利跑出結果也是很欣慰了。這學期學習到的模型、分析方法也透過報告比較理解該如何運用了,期末報告真的讓我獲益良多。

六、参考資料

https://towardsdatascience.com/predicting-destination-countries-for-new-users

of-airbnb-eb0d7db7579f

https://towardsdatascience.com/predicting-airbnb-prices-using-machine-learning

in-vancouver-1b42ca52eece

https://www.dataquest.io/blog/machine-learning-tutorial/

https://github.com/karvenka/kaggle-airbnb

https://www.kaggle.com/raghavendrakotala/airbnb-springboard-eda

https://medium.com/finformation%E7%95%B6%E7%A8%8B%E5%BC%8F%E9%81%87%E4%B8%8A%E8%B2%A1%E5%8B%99%E9%87%91%E8%9E%8D/%E7%B6%B2%E7%AB%99%E6%8E%A8%E8%96%A6%E7%B3%BB%E7%B5%B1%E5%BB%BA%E7%BD%AE-

 $\frac{\%\,E6\%\,88\%\,91\%\,E6\%\,80\%\,8E\%\,E9\%\,BA\%\,BC\%\,E5\%\,88\%\,86\%\,E6\%\,9E\%\,90\\airbnb\%\,E7\%\,9A\%\,84\%\,E8\%\,B3\%\,87\%\,E6\%\,96\%\,99-1bbac\,91ba\,723$

https://blog.csdn.net/Datawhale/article/details/80847662

https://github.com/karvenka/kaggle

airbnb/blob/master/notebooks/Venkatesan_Karthick_Final_Project Report.ipvnb

 $\underline{https://codertw.com/\%E7\%A8\%8B\%E5\%BC\%8F\%E8\%AA\%9E\%E8\%A8\%80/369869/}$